

CRAB: 基於自監督語音與文字模型的多模態情緒辨識與深偽語音偵測框架

Speech and Language Processing Project Report

簡子霖

逢甲大學資訊工程所

M1406785@o365.fcu.edu.tw

1 摘要

本研究實作 CRAB，一套針對語音情緒辨識 (speech emotion recognition, SER) 與深偽語音偵測 (audio deepfake detection) 的研究型框架。系統以自監督語音模型 (self-supervised learning, SSL) 抽取聲學表徵，並結合 RoBERTa 文字編碼器擷取語意表徵，再透過投影層、雙向 GRU、跨模態注意力與注意力池化完成語音與文字融合。在情緒辨識任務中，框架支援 MELD、IEMOCAP 與 MSP-Podcast；在深偽語音偵測任務中，框架支援 ASVspoof2019、ASVspoof2021 與 ASVspoof5。訓練流程提供加權交叉熵、多正例對比式學習與 pairwise Gaussian loss 等目標函數，並以 UAR/WAR 或 EER/Act-DCF 作為任務對應評估指標。本文整理此專案的資料處理、模型設計、訓練策略與可重現實驗設定，作為後續大規模實驗與模型比較的基準文件。

關鍵字：語音情緒辨識、深偽語音偵測、自監督學習、多模態融合、ASVspoof

2 緒論

語音訊號同時包含語者狀態、語意內容、韻律與錄音環境等多層資訊。在情緒辨識任務中，模型需從聲學線索與文字內容判斷說話者情緒；在深偽語音偵測任務中，模型則需要辨識語音是否由語音合成、聲音轉換或其他生成技術產生。兩者雖然任務目標不同，但皆仰賴穩健的語音表徵與有效的序列建模。

近年 wav2vec 2.0、HuBERT 與 WavLM 等 SSL 語音模型已能從大量未標註語料中學得具泛化能力的表徵 [1–3]。另一方面，RoBERTa 等預訓練語言模型能提供上下文文化文字特徵 [4]。因此，本專案將語音 SSL encoder 與文字 transformer encoder 作為前端特徵抽取器，並在任務特定的融合模組中學習聲學與語意資訊之間的互補關係。

本專案的主要貢獻如下：

1. 建立一套可由 YAML 設定檔控制的多任務語音框架，支援情緒辨識與深偽語音偵測。
2. 設計以 SSL 語音特徵與 RoBERTa 文字特徵為輸入的多模態融合模型，結合雙向 GRU、跨模態注意力與注意力池化。
3. 整合任務對應資料集、動態 batch sampler、混合精度訓練、checkpoint 管理與 WandB 紀錄。
4. 提供 SSL embedding 匯出與 t-SNE 後處理流程，便於分析不同訓練階段的表徵分布。

3 相關研究

3.1 自監督語音表徵

wav2vec 2.0 透過遮罩潛在語音表徵與對比式學習，在少量標註資料下仍能取得強健語音表示 [1]。HuBERT 以離線分群產生隱藏單元作為預測目標，將 BERT 式遮罩預測延伸到連續語音訊號 [2]。WavLM 進一步加入去噪與 gated relative position bias，強化非 ASR 語音任務的泛化能力 [3]。本專案的

‘SSLModel’ 同時支援 torchaudio pipeline 與 Hugging Face backend，可依設定選用 WavLM、wav2vec 2.0、HuBERT 或 XLS-R 系列模型。

3.2 多模態情緒辨識

MELD 提供多方對話中的文字、音訊與視覺資訊，並標註七類情緒與情感極性 [5]。IEMOCAP 則以雙人互動情境蒐集語音、文字、視覺與 motion capture 資料，是 SER 研究常用資料集 [6]。MSP-Podcast 以自然 podcast 語音建立大規模情緒語料，資料分布更接近真實場景 [7]。相較於只使用單一模態，本專案在模型中同時保留音訊與文字路徑，並以跨模態注意力讓兩種序列特徵互相查詢。

3.3 深偽語音偵測

ASVspoof 系列挑戰提供合成語音、聲音轉換、重放攻擊與 deepfake speech 的公開評測資料與 protocol [8–10]。此類任務通常以 Equal Error Rate (EER) 與 detection cost function 衡量系統在 bona fide 與 spoof speech 之間的決策能力。CRAB 的 deepfake pipeline 以 ASVspoof protocol 載入標籤與 trial file，並可輸出官方評測格式的分數檔。

4 方法

4.1 系統架構

圖像與影片模態雖可提升部分資料集的辨識能力，但本專案目前聚焦於音訊與文字兩種可穩定取得的模態。整體架構由三個主要模組組成：

1. **Speech SSL encoder**：輸入 16 kHz waveform，輸出 frame-level speech representation。
2. **Text encoder**：輸入 tokenizer 產生的 token ID 與 attention mask，輸出 contextual text representation。
3. **SER fusion head**：將兩種模態投影到共同維度，進行序列建模、跨模態注意力、池化、融合與分類。

令語音 SSL 輸出為 $A \in \mathbb{R}^{T_a \times d_a}$ ，文字 encoder 輸出為 $T \in \mathbb{R}^{T_t \times d_t}$ 。模型先以線性層投影至共同維度 d 並進行 layer normalization：

$$\tilde{A} = \text{LN}(AW_a), \quad \tilde{T} = \text{LN}(TW_t). \quad (1)$$

接著兩個雙向 GRU 分別建模語音與文字序列：

$$H_a = \text{BiGRU}_a(\tilde{A}), \quad H_t = \text{BiGRU}_t(\tilde{T}). \quad (2)$$

跨模態注意力採用 multi-head attention 的 query-key-value 形式 [11]：

$$C_a = \text{MHA}(Q = H_a, K = H_t, V = H_t), \quad C_t = \text{MHA}(Q = H_t, K = H_a, V = H_a). \quad (3)$$

最後以殘差連接形成 $F_a = H_a + C_a$ 與 $F_t = H_t + C_t$ ，再透過可學習注意力池化取得 utterance-level 向量：

$$z_m = \sum_i \alpha_i F_{m,i}, \quad \alpha_i = \text{softmax}(w^\top F_{m,i}), \quad m \in \{a, t\}. \quad (4)$$

兩個模態的池化向量串接後，經 layer normalization、線性投影、ReLU、dropout 與分類器輸出 logits。

4.2 訓練目標

分類任務的主要目標為交叉熵或加權交叉熵。對於類別不平衡的情緒資料，框架可由訓練集標籤統計自動估計 class weight：

$$w_c = \frac{N}{K \cdot N_c}, \quad (5)$$

其中 N 為訓練樣本數、 K 為類別數、 N_c 為類別 c 的樣本數。

為了讓同類樣本在表示空間中更接近，模型也支援 multi-positive contrastive loss。給定 batch embedding e_i 與 label y_i ，同 label 且非自身的樣本被視為 positive pair；loss 以 temperature τ 計算 normalized similarity，再對多個 positive 平均分配目標機率。此設計與多正例對比式學習的精神一致 [12]。此外，框架保留 pairwise Gaussian loss，可對成對 embedding 的歐氏距離加入額外約束。

4.3 資料前處理

所有音訊皆統一載入為單聲道 waveform，若取樣率不是 16 kHz 則重採樣至 16 kHz，並以 peak normalization 將振幅縮放到一致尺度。情緒資料若含文字 transcript，會使用 RoBERTa tokenizer 轉成固定長度 token 序列，目前上限為 128。batch collate 時會根據 waveform 長度補齊音訊，並產生 audio mask；文字則由 tokenizer 的 attention mask 標示有效 token。

深偽語音資料依 ASVspoof protocol 讀取檔名與 bona fide/spoof 標籤。若設定啟用 duration features，dataset 也能載入口語單位、母音與子音時間長度資訊；不過目前主要模型路徑仍以 waveform SSL representation 為核心。

5 實驗設計

5.1 資料集與標籤

表 1 整理目前程式支援的資料集與標籤設定。情緒辨識任務輸出多類別 label；深偽語音偵測任務輸出二元 label，其中 0 代表 bona fide，1 代表 spoof。

Table 1: 專案支援資料集與任務設定

資料集	任務	標籤設定	評估指標
MELD	情緒辨識	neutral, surprise, fear, sadness, joy, disgust, anger	UAR, WAR
IEMOCAP	情緒辨識	neutral, joy/happiness, anger, sadness	UAR, WAR
MSP-Podcast	情緒辨識	neutral, surprise, fear, sadness, joy, disgust, anger, other	UAR, WAR
ASVspoof2019/2021/5	深偽語音偵測	bona fide, spoof	EER, Act-DCF

5.2 模型與最佳化設定

情緒辨識設定以 HuBERT Large 作為語音 encoder，RoBERTa Base 作為文字 encoder，融合模組隱藏維度 $d = 512$ ，dropout 為 0.5。IEMOCAP 與 MSP-Podcast 設定使用 CosineAnnealingLR，並對 SSL encoder、text encoder 與 SER head 設定不同 learning rate；MELD 設定則使用 stepwise division scheduler。深偽語音偵測設定以 wav2vec 2.0 XLS-R 300M 作為語音 encoder，融合維度 $d = 256$ ，主要使用交叉熵與 label smoothing；但目前 YAML 未明確覆寫文字模型與類別數，仍需在正式實驗前修正為純語音 head 或補齊文字輸入。表 2 列出目前 YAML 設定檔中的主要實驗配置。

Table 2: 主要實驗設定

設定檔	SSL / text model		Epoch	Batch size	Loss
emotion/MELD	HuBERT	Large	/ 1	4/4/1	WCE + MPCL
	RoBERTa Base				
emotion/IEMOCAP	HuBERT	Large	/ 20	4/4/4	WCE + MPCL
	RoBERTa Base				
emotion/MSP_Podcast	HuBERT	Large	/ 20	16/16/1	WCE + MPCL
	RoBERTa Base				
deepfake/baseline	XLS-R	300M	/ 32	16/32/32	CE
	RoBERTa default				

5.3 訓練與評估流程

實驗由 ‘src/main.py’ 讀取 ‘configs/’ 中的 YAML 設定檔後啟動。訓練前會固定隨機種子、建立工作目錄、載入模型、統計參數量並建立 dataloader。訓練過程支援 fp16/bf16 混合精度、gradient accumulation、gradient clipping、scheduler step、checkpoint 儲存與 WandB 紀錄。對情緒辨識任務，最佳模型依 dev set UAR 選擇；對深偽語音偵測任務，最佳模型依 dev set EER 選擇。

情緒辨識的評估輸出 WAR 與 UAR：

$$\text{WAR} = \frac{\sum_i \mathbb{I}(\hat{y}_i = y_i)}{N}, \quad \text{UAR} = \frac{1}{K} \sum_{c=1}^K \frac{\sum_i \mathbb{I}(\hat{y}_i = c, y_i = c)}{\sum_i \mathbb{I}(y_i = c)}. \quad (6)$$

深偽語音偵測則以 softmax spoof score 計算 EER，並在產生 ‘evaluation_scores.txt’ 後呼叫 ASVspoof 評測模組計算 minDCF、EER、CLLR 與 Act-DCF。

5.4 表徵分析

情緒模型提供 ‘extract_ssl_embedding’ 介面，可在 epoch 0、best checkpoint 與最後一個 epoch 匯出 pooled SSL embeddings。匯出的 ‘.npz’ 檔包含 embedding、label、emotion name、dataset、split、filename、frame length、stage 與 epoch 等欄位。後處理程式 ‘postprocess/main.py’ 可對這些 embedding 進行 StandardScaler、PCA 與 t-SNE，並輸出互動式 HTML 圖與 CSV。此流程可用來比較模型微調前後，同一情緒類別是否形成更清楚的群聚。

6 討論

6.1 架構優點

CRAB 的模組化設計讓語音 SSL encoder、文字 encoder、融合 head、loss 與資料集設定彼此解耦。因此研究者可以在不重寫訓練流程的前提下替換 HuBERT、WavLM、wav2vec 2.0 或不同文字模型，也可以透過 YAML 設定調整 batch sampler、learning rate、loss 權重與 embedding export。跨模態 attention 的設計讓語音序列能查詢文字序列，文字序列也能回看語音線索，適合處理語意與語調都會影響判斷的情緒任務。

6.2 限制

目前深偽語音模型檔案沿用與情緒模型相近的融合 head，但 ASVspoof batch 並未預設提供文字 token；若要完全支援 audio-only deepfake pipeline，模型 forward path 應明確處理 ‘tokens’ 與 ‘text_mask’ 為空的情況，或改為純語音分類 head。除此之外，‘DeepfakeBaselineModelConfig’ 的預設 ‘num_classes’ 為 8，而 ASVspoof 標籤是 bona fide/spoof 二元分類，因此正式訓練前應在 YAML 中明確設定 ‘num_classes’。

2’ 或調整 dataclass 預設。此外，現有 repository 未保存可驗證的正式實驗分數，因此本文不回報測試集數值結果。後續應補上完整實驗紀錄、固定資料版本、checkpoint hash 與多組 seed 平均，才能形成可比較的 benchmark。

7 結論

本文整理並撰寫 CRAB 專案的論文式報告。此框架以 SSL 語音模型與 RoBERTa 文字模型為基礎，透過雙向 GRU、跨模態 attention 與 attention pooling 建立多模態語音分類模型，並同時支援 SER 與 deepfake detection 的資料處理、訓練與評估流程。未來工作將聚焦於三個方向：第一，補齊 audio-only deepfake head，使 ASVspoof pipeline 與情緒 pipeline 更清楚分工；第二，加入正式實驗表格與 ablation study，比較 SSL encoder、文字模態、MPCL 與 sampler 的影響；第三，將 embedding visualization 與錯誤分析納入標準報告流程，以提升模型可解釋性。

References

- [1] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations, 2020.
- [2] Wei-Ning Hsu, Benjamin Bolte, Yao-Hung Hubert Tsai, Kushal Lakhotia, Ruslan Salakhutdinov, and Abdelrahman Mohamed. Hubert: Self-supervised speech representation learning by masked prediction of hidden units, 2021.
- [3] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, Jian Wu, Long Zhou, Shuo Ren, Yanmin Qian, Yao Qian, Jian Wu, Michael Zeng, Xiangzhan Yu, and Furu Wei. Wavlm: Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6):1505–1518, 2022.
- [4] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach, 2019.
- [5] Soujanya Poria, Devamanyu Hazarika, Navonil Majumder, Gautam Naik, Erik Cambria, and Rada Mihalcea. MELD: A multimodal multi-party dataset for emotion recognition in conversations. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 527–536, 2019.
- [6] Carlos Busso, Murtaza Bulut, Chi-Chun Lee, Abe Kazemzadeh, Emily Mower, Samuel Kim, Jeannette N. Chang, Sungbok Lee, and Shrikanth S. Narayanan. IEMOCAP: Interactive emotional dyadic motion capture database. *Language Resources and Evaluation*, 42(4):335–359, 2008.
- [7] Carlos Busso, Reza Lotfian, Kusha Sridhar, Ali N. Salman, Wei-Cheng Lin, Lucas Goncalves, Srinivas Parthasarathy, Abinay Reddy Naini, Seong-Gyun Leem, Luz Martinez-Lucas, Huang-Cheng Chou, and Pravin Mote. The msp-podcast corpus, 2025.
- [8] Massimiliano Todisco, Xin Wang, Ville Vestman, Md Sahidullah, Hector Delgado, Andreas Nautsch, Junichi Yamagishi, Nicholas Evans, Tomi Kinnunen, and Kong Aik Lee. ASVspoof 2019: Future horizons in spoofed and fake audio detection. In *Proceedings of Interspeech 2019*, pages 1008–1012, 2019.
- [9] Junichi Yamagishi, Xin Wang, Massimiliano Todisco, Md Sahidullah, Jose Patino, Andreas Nautsch, Xuechen Liu, Kong Aik Lee, Tomi Kinnunen, Nicholas Evans, and Hector Delgado. ASVspoof 2021: Accelerating progress in spoofed and deepfake speech detection. In *Proceedings of the ASVspoof Challenge Workshop*, pages 47–54, 2021.
- [10] ASVspoof Challenge Organizers. ASVspoof 5 challenge. <https://www.asvspoof.org/>, 2024. Accessed 2026-06-09.

- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [12] Yonglong Tian, Lijie Fan, Phillip Isola, Huiwen Chang, and Dilip Krishnan. Stablerep: Synthetic images from text-to-image models make strong visual representation learners, 2023.